

Análisis Exploratorio del Rendimiento Estudiantil

David Fonseca Lara
Juan Esteban Avendaño Castaño

1 Introducción

El presente documento resume el análisis exploratorio realizado en el notebook `EDA and cleaning.ipynb`, el cual utiliza el dataset *Students Performance in Exams* de Kaggle. Este dataset contiene información sobre el rendimiento académico de estudiantes en tres áreas principales: matemáticas, lectura y escritura.

El objetivo principal es comprender las desigualdades en el desempeño escolar, identificando patrones de distribución, variabilidad y la presencia de casos extremos.

2 Problema abordado

Se busca responder preguntas clave como:

- ¿Existen diferencias sistemáticas entre el desempeño en matemáticas, lectura y escritura?
- ¿Qué tan grande es la variabilidad en los puntajes entre estudiantes?
- ¿Se observan valores atípicos que podrían indicar problemas estructurales o anomalías en la recolección de datos?

3 Problemas similares en la literatura

El tema del rendimiento escolar ha sido ampliamente estudiado, con énfasis en factores socioeconómicos, culturales y de género.

El *Coleman Report* (1966) mostró que el contexto socioeconómico es determinante en los logros académicos, más allá de los recursos escolares disponibles.

De manera complementaria, los informes de la OCDE, en particular el *Programme for International Student Assessment (PISA)* desde el año 2000, han documentado brechas persistentes en el rendimiento escolar vinculadas al género y al nivel socioeconómico.

Un metaanálisis de Sirin (2005) confirma que el nivel socioeconómico de los estudiantes y sus familias es uno de los predictores más sólidos de éxito académico.

4 Análisis general del notebook

El análisis exploratorio realizado ofrece varias observaciones clave:

1. **Distribuciones de puntajes:** Los resultados en matemáticas, lectura y escritura son relativamente balanceados, con medias cercanas a las medianas. Esto sugiere ausencia de sesgos muy fuertes.
2. **Variabilidad significativa:** La desviación estándar en torno a 15 puntos refleja una dispersión considerable. Algunos estudiantes alcanzan puntajes sobresalientes (100), mientras otros presentan un rendimiento muy bajo (cercano a 0).
3. **Asimetría en lectura y escritura:** Las distribuciones muestran un sesgo hacia valores bajos, evidenciando un grupo de estudiantes con dificultades en estas áreas.
4. **Detección de outliers:** Casos como un puntaje de 0 en matemáticas sugieren posibles anomalías: ausencia en el examen, errores de captura de datos o situaciones de vulnerabilidad extrema en el aprendizaje.

En conjunto, los hallazgos muestran un núcleo de estudiantes con rendimiento medio-alto, pero también desigualdades profundas que hacen evidente la necesidad de políticas educativas enfocadas en atender tanto a los estudiantes en riesgo como en la identificación temprana de patrones de desigualdad académica.

5 Referencia del código

El código utilizado para el análisis exploratorio se encuentra disponible en el siguiente repositorio:

https://github.com/Adrephos/machinelearning/blob/master/project/entrega%201/EDA_and_cleaning.ipynb

Referencias

- Coleman, J. S., et al. (1966). *Equality of Educational Opportunity*. Washington, DC: U.S. Government Printing Office.
- OECD. (2019). *PISA 2018 Results (Volume I): What Students Know and Can Do*. OECD Publishing. <https://doi.org/10.1787/5f07c754-en>
- Sirin, S. R. (2005). Socioeconomic Status and Academic Achievement: A Meta-Analytic Review. *Review of Educational Research*, 75(3), 417–453. <https://doi.org/10.3102/00346543075003417>